Institute of Field Robotics, King Mongkut's University of Technology Thonburi
126 Pracha Uthit Rd, Bang Mot, Thung Khru, Bangkok, Thailand 10140
Senior Thesis FRAB (FIBO Robotics and Automation: Bachelor)
Copyright © 2021 by FIBO

Bachelor Degree Thesis

A BAYESIAN APPROACH-BASED AREA TRACKING

Kongphop Thongdee, 63340500003 [1]
Thanachart Satianjarukarn, 63340500021 [1]

Dr.Thavida Maneewarn, PhD. [1,*]

[1]Affliation, e.g lab name, FIBO
[2] Affiliation

*Advisor **
*Co-advisor **

ABSTRACT:
Match moving is a technique used in cinema to determine the camera movement model. Traditional point-based tracking systems can be less robust in quickly changing perspectives. In cinema, the area lacks distinctive features, and the human is also part of the process. However, the system obtains training data from only the first frame. This paper proposes a Bayesian approach-based area tracking by combining 2 metrics: 1) the homogeneous area metric, which detects the sub-features area. 2) the local color metric, which detects the region of interest. Both metrics utilize Bayesian learning to calculate the probability image. The local color tracking extracts the statistical analysis from the ellipse mask generated by user provided in the first frame of the video sequence to track in the next frame. Region growing is then performed, and ellipse is fitted to generate the ellipse masks which is similar to ROI area in first frame. The homogeneous tracking applies the Gaussian image pyramid four times, followed by homogeneous feature extraction to calculate probability from the pre-trained Bayesian model to create the sub-feature on ROI area.

Keywords: Bayesian, Region growing, Gaussian image pyramid, homogeneity analysis, color transform

Institute of Field Robotics, King Mongkut's University of Technology Thonburi
126 Pracha Uthit Rd, Bang Mot, Thung Khru, Bangkok, Thailand 10140
Senior Thesis FRAB (FIBO Robotics and Automation: Bachelor)
Copyright © 2021 by FIBO

วิทยานิพนธ์ระดับปริญญาตรี

Bayesian approach area tracking

นายก้องภพ ทองดี,
63340500003[1]
ธนชาติ เสถียรจารุการ,
63340500021[1]
ดร.ถวิดา มณีวรรณ[1,*]

1Affliation, e.g lab name, FIBO
2 Affiliation
*อาจารย์ที่ปรึกษา **
อาจารย์ที่ปรึกษาร่วม

บทคัดย่อ

เทคนิคการทำ Match moving ในภาพยนตร์ที่ใช้สำหรับการหาโมเดลการเคลื่อนที่ของกล้อง วิธีการดั้งเดิมคือการติดตามด้วยจุดมีความไม่คงทนเมื่อมีการเปลี่ยนแปลงมุมมองของกล้อง อย่างไรก็ตาม area ในวิดิโอมีคุณลักษณะที่แตกต่างกันและไม่มีความโดดเด่นในคุณลักษณะ แต่มีมนุษย์เป็นส่วนหนึ่งในการติดตาม โครงงานนี้นำเสนอระบบติดตามพื้นที่โดยการประยุกต์ใช้ทฤษฎีของเบย์ โดยระบบแบ่งสองส่วนหลักคือ 1. ระบบตรวจเช็คสีในพื้นที่ 2. ระบบตรวจจับพื้นที่ที่มีเนื้อเดียวกัน ระบบทั้งสองประยุกต์ใช้หลักการเรียนรู้ของเบย์เข้ามาเพื่อคำนวณหาค่าความน่าจะเป็น โดยระบบตรวจเช็คสีในพื้นที่คำนวณความน่าจะเป็นที่จะเป็นสีเดียวกับพื้นที่ที่สนใจด้วยทฤษฎีของเบย์โดยใช้ข้อมูลทางสถิติของสีที่ถูกเรียนรู้ใน frame ที่ 1 และนำไปทำ Region growing เพื่อแบ่งกลุ่มเพื่อนำสร้าง ellipse mask และเลือกบริเวณที่มีลักษณะเดียวกันกับบริเวณที่ต้องการติดตามสำหรับส่งต่อให้ระบบตรวจจับพื้นที่ที่มีเนื้อเดียวกันโดยใช้หลักการของ Gaussian image pyramid ตามด้วยการจำแนกคุณลักษณะความเป็นเนื้อเดียวกัน คำนวณความน่าจะเป็นที่จะเป็นเนื้อเดียวกันด้วยทฤษฎีของเบย์ และข้อมูลทางสถิติที่ถูกเรียนรู้มาก่อนหน้าเพื่อนำไปประยุกต์หาคุณลักษณะย่อยภายในบริเวณที่ติดตาม

คำสำคัญ: Bayesian learning, Gaussian image pyramid, homogeneity analysis, color transform

1. บทนำ (Introduction)

1.1 ที่มาและ ความสำคัญ

เทคนิคการทำ Match moving ในภาพยนตร์คือการติดตามจุดต่างๆในแต่ละ frame ของภาพยนต์เพื่อหาโมเดลการเคลื่อนที่ของกล้อง แต่ด้วยข้อจำกัดของการติดตามด้วยจุดเมื่อมีการเปลี่ยนแปลงมุมมองของกล้อง จุดต่างๆที่ถูกติดตามใน frame ก่อนหน้าอาจถูกรบกวนด้วย environment ที่เปลี่ยนแปลงไปทำให้ไม่สามารถติดตามจุดเหล่านั้นได้อย่างแม่นยำ นอกจากนี้การติดตามด้วยจุดมีความไม่คงทนต่อการ เปลี่ยนแปลงมุมมองกล้องอย่างรวดเร็ว การสั่นสะเทือน และใช้จำนวนจุดมาก เพื่อหาโมเดลการเคลื่อนที่ของกล้องให้ออกมาอย่างแม่นยำ ทางบริษัท YANNIX จึงมีแนวทางในการวิจัยระบบติดตามแบบพื้นที่โดยใช้สองคุณลักษณะของพื้นที่ที่สำคัญคือ ความเป็นเนื้อเดียวกัน และค่าสีโดยรวมทั้งสองคุณลักษณะออกมาเป็นความน่าจะเป็นที่จะเป็นพื้นที่เดียวกับ frame ก่อนหน้าโดยใช้หลักการทางสถิติของ Bayes โครงงานนี้จึงจัดทำเพื่อสร้างระบบ proof of concept ในการติดตามพื้นที่ใน frame ถัดไปโดยการประยุกต์ใช้หลักการ Bayesian learning ร่วมกับคุณลักษณะความเป็นเนื้อเดียวกันและคุณลักษณะที่เกี่ยวกับสี เพื่อเป็นแนวทางและศึกษาหาข้อจำกัดให้ทางบริษัทนำไป ประยุกต์ใช้พัฒนาซอฟต์แวร์ที่มีอยู่ในบริษัทให้มีความแม่นยำ และคงทนต่อสภาพแวดล้อมที่เปลี่ยนแปลงจากมุมมองของกล้องที่เปลี่ยนแปลงไป

1.2 จุดประสงค์โครงการ

1. เพื่อศึกษาและประยุกต์ใช้หลักการ Bayesian learning ร่วมกับคุณลักษณะความเป็นเนื้อเดียวกัน และคุณลักษณะที่เกี่ยวข้องกับค่าสี ในการสร้างระบบติดตามพื้นที่ในวิดีโอ
2. เพื่อศึกษาแนวทางและข้อจำกัดของระบบ Bayesian area tracking ในการติดตามพื้นที่ที่สนใจบนวิดีโอ
3. เพื่อศึกษากระบวนการและคุณลักษณะที่โดดเด่นในความเป็นเนื้อเดียวกัน และคุณลักษณะที่เกี่ยวข้องกับค่าสี
4. สร้างระบบ proof of concept ในการทำ Bayesian area tracking เพื่อเป็นแนวทางในการพัฒนาและประยุกต์ใช้

1.3 ขอบเขต

1. โครงงานนี้ทำการศึกษาในคุณลักษณะของความเป็นเนื้อเดียวกัน และคุณลักษณะที่เกี่ยวข้องกับค่าสีเท่านั้น
2. ใช้หลักการของ Bayesian learning ในการคำนวณความน่าจะเป็นที่จะเป็นพื้นที่เดียวกันใน frame ก่อนหน้า
3. ระบบ Bayesian area tracking เป็นระบบ proof of concept เพื่อศึกษาหาแนวทางและข้อจำกัดของระบบ
4. ลักษณะของวิดีโอที่ใช้ในการติดตามพื้นที่เป็นวิดีโอที่มีการถ่ายทำอย่างต่อเนื่อง กล่าวคือแต่ละ frame มีความใกล้เคียงกัน
5. ข้อมูลที่ใช้ในการติดตามพื้นที่ในวิดีโอคือพื้นที่ที่สนใจใน frame ก่อนหน้า และระบบจะทำการหาความน่าจะเป็นที่จะเป็นพื้นที่ที่สนใจใน frame ก่อนหน้าในทุก pixel ของ frame ถัดไป

2. ทบทวนวรรณกรรม และ ทฤษฎีที่เกี่ยวข้อง (Literature Review)

2.1. Bayesian Theorem

ทฤษฎีของเบย์ [7] เป็นหลักการพื้นฐานทางสถิติที่ใช้คำนวณความน่าจะเป็นที่จะเกิดเหตุการณ์หนึ่งเมื่อเหตุการณ์หนึ่งเกิดขึ้น ซึ่งในโครงงานนี้ประยุกต์ใช้ทฤษฎีของเบย์เพื่อใช้ในการคำนวณหาค่าความน่าจะเป็นของเหตุการณ์โดยมีสมการดังต่อไปนี้

$$\mathrm{P}(class|score) = \frac{\mathrm{P}(class) \cdot \mathrm{P}(score|class)}{\mathrm{P}(\sim class) \cdot \mathrm{P}(score|\sim class) + \mathrm{P}(class) \cdot \mathrm{P}(score|class)}$$

โดยที่ $\mathrm{P}(score|class)$ คือความน่าจะเป็นของ score นั้นๆเมื่ออยู่ในคลาสหนึ่ง $\mathrm{P}(class|score)$ คือความน่าจะเป็นของ class เมื่อกำหนดค่า score และ $\mathrm{P}(class)$ คือความน่าจะเป็นของ class ในงานวิจัย Bayesian Classification of Image Structures [9] ได้ประยุกต์ใช้ทฤษฎีของเบย์ในการ classify โครงสร้างในภาพซึ่งได้แก่ ความเป็นเนื้อเดียวกัน ขอบ มุม และ พื้นผิวโดยใช้คุณลักษณะที่บ่งบอกถึงพื้นผิวบนภาพ ผลลัพธ์แสดงแนวทางในการประยุกต์ใช้ค่าทางสถิติของ neighbor pixel เพื่อแสดงถึงคุณลักษณะซึ่งให้ผลลัพธ์สูงที่สุด นอกจากนี้งานวิจัย A Bayesian Approach to Digital Matting [10] ประยุกต์ใช้หลักการ maximum a posterior ซึ่งเป็นหนึ่งในการใช้งานทฤษฎีของเบย์ เพื่อทำการ matting บนวิดีโอโดยใช้คุณลักษณะทางสถิติเพื่อดึงค่าสีของ neighbor pixel แสดงให้เห็นถึงความสามารถของการประยุกต์ใช้ทฤษฎีของเบย์ซึ่งให้ผลลัพธ์ที่ดีกว่า traditional method ในการทำ matting

2.2. Multivariate Gaussian Distribution

Multivariate Gaussian distributions [8] เป็นรูปแบบการกระจายตัวแบบปกติของข้อมูลหลายมิติหรือการแจกแจงแบบปกติหลายตัวแปรของเวกเตอร์สุ่ม $X = [x_1, x_2, \dots, x_n]$ เมื่อเวกเตอร์สุ่มหลายตัวแปลมีลักษณะการกระจายตัวแบบปกติด้วยค่าเฉลี่ย $\vec{\mu}$ และแมทริกซ์ความแปรปรวน Σ จะสามารถโมเดล probability density function ได้ดังสมการดังต่อไปนี้

$$p(X; \vec{\mu}, \Sigma) = \frac{1}{(2\pi^{\frac{n}{2}}|\mathbf{\Sigma}|^{\frac{1}{2}})} \exp -\frac{1}{2}(X - \vec{\mu})^T \mathbf{\Sigma}^{-1}(X - \vec{\mu})$$

เราสามารถเขียนเวกเตอร์สุ่มหลายตัวแปลที่มีลักษณะการกระจายตัวแบบปกติได้ด้วยสัญลักษณ์ $X \sim \mathcal{N}(\vec{\mu}, \mathbf{\Sigma})$ ด้วยคุณลักษณะของสีที่มีความ dependency กันในแต่ละ channel ของสีทำให้การโมเดลข้อมูลที่เกี่ยวข้องกับคุณลักษณะของสีจำเป็นต้องใช้โมเดล multivariate Gaussian distributions สำหรับการวิเคราะห์และคำนวณความน่าจะเป็นของข้อมูล

2.3. General color model

งานทางด้าน Computer vision นิยมประยุกต์ใช้สี Color model เช่น RGB เป็นระบบสีที่มีพื้นฐานจากแม่สีที่เกิดจากอุปกรณ์ถ่ายภาพและเมื่อนำแม่สีทั้ง 3 สีมาผสมกันสามารถทำให้เกิดเป็นรูปภาพ, YCbCr เป็นระบบสีที่แสดงความสว่าง ความต่างสีแดงและฟ้า สำหรับการ วิเคราะห์ และจัดการ

ข้อมูลสีที่สอดคล้องกับการรับรู้ของมนุษย์ ดั้งนั้นทางคณะผู้จัดทำทำการศึกษาและประยุกต์ color model เพื่อใช้ร่วมกันตามหน้าที่ของแต่ละคุณสมบัติที่ต้องการตรวจสอบ

2.4 GAUSSIAN IMAGE PYRAMID

Gaussian image pyramid เป็นเทคนิคในการประมวลผลภาพที่ช่วยให้การวิเคราะห์องค์ประกอบภายในภาพสามารถทำได้โดยไม่สนใจขนาดของวัตถุภายในภาพ โดยเทคนิคนี้ประยุกต์ใช้การ convolution ด้วย Gaussian kernel และ stride 2 ในแต่ละครั้งของการ convolve ในแต่ละชั้นของ pyramid จะได้รูปภาพที่มีขนาดต่ำกว่าภาพในชั้นที่สูงกว่าครึ่งหนึ่ง โดยจำนวนชั้นของ pyramid ที่ทำให้คุณภาพของภาพยังคงไม่สูญหายคือจำนวณ 4 ชั้นจากการทดลองในงานลักษณะเดียวกัน [1] ในงานวิจัยอ้างอิงได้ทำการทดลอง classify species ของไม้ซึ่งแตกต่างกันเพียง texture ของเนื้อไม้ โดยมีจำนวนขั้นของ pyramid เป็น parameter เมื่อจำนวนขั้น pyramid เพิ่มขึ้นมากกว่า 4 จะทำให้ประสิทธิภาพในการทำนายแย่ลง

2.5 REGION GROWING

Region growing เป็นหนึ่งใน algorithm สำหรับการทำ segmentation บนรูปภาพด้วยวิธีการเสิร์จหาในแต่ละ pixel เพื่อทดสอบคุณลักษณะของ neighbor pixel โดยใช้การกำหนด criteria ซึ่งใช้มาตรวัตรต่างๆ เข้ามาประยุกต์ใช้เพื่อทำให้การแบ่งแยก region ดีขึ้นได้เช่น Gaussian Mixture, FCM [2] ในโครงงานนี้จำเป็นต้องแยกกลุ่มของพื้นที่ที่เหมือนกันจาก probability image การใช้วิธี region-growing จึงเป็นวิธีที่เหมาะสมสำหรับการสร้าง mask เพื่อนำไปใช้ในการ fit ellipse สำหรับการสร้าง ellipse mask เพื่อใช้ในการตรวจจับพื้นที่ที่สนใจ

2.6 Multimodal Distribution

Multimodal distribution [11] เป็นรูปแบบการกระจายตัวแบบปกติของข้อมูลที่มีมากกว่า 1 mode ซึ่งจะเกิดจากโมเดล probability density function ของข้อมูลในแต่ละ mode นำมารวมกัน และข้อมูลของแต่ละ mode จะมีข้อมูลเวกเตอร์สุ่มหลายตัวแปล ค่าเฉลี่ย μ และแมทริกซ์ความแปรปรวน Σ โดยสามารถนำ probability density function ของแต่ละ mode มารวมกันด้วยสมการดังนี้

$$f(x) = Pg_1(x) + (1-P)g_2(x)$$

โดยที่ $f(x)$ คือผลรวมของการแจกแจงแบบปกติหลายตัวแปรของ mode ทั้งหมด P คือความน่าจะเป็นของ mode นั้นๆ เมื่ออยู่ในคลาสหนึ่ง และ $g_n(x)$ คือการแจกแจงแบบปกติหลายตัวแปรของ mode นั้นๆ

2.7 Otsu's thresholding

Otsu's thresholding [14] เป็นอัลกอลิทึมหนึ่งที่ใช้ในการแบ่งกลุ่มของข้อมูลบนภาพโดยใช้ความเข้มของสี โดยกระบวนการของ Otsu's จะทำการหาค่า threshold ที่ทำให้สมการดังต่อไปนี้มีค่าสูงที่สุด

$$\lambda = \frac{\sigma_B^2}{\sigma_W^2}, \quad \kappa = \frac{\sigma_T^2}{\sigma_W^2}, \quad \eta = \frac{\sigma_B^2}{\sigma_T^2}$$

โดยที่ $\sigma_W^2, \sigma_B^2, \sigma_T^2$ คือค่าความแปรปรวนภายในคลาส ความแปรปรวนระหว่างคลาส และความแปรปรวนทั้งหมดตามลำดับ โดยค่า threshold นี้จะทำให้เราสามารถแบ่งข้อมูลได้เป็นสองส่วน กล่าวคือได้ Gaussian parameters ที่แสดงถึงการกระจายตัวของแต่ละ cluster ซึ่งสามารถนำ parameters เหล่านี้ไปใช้ในการทำ region growing ได้

2.8 K-mean Clustering

K-mean clustering [13] เป็นอัลกอลิทึมสำหรับการแบ่งกลุ่มข้อมูล เนื่องจากบริเวณที่สนใจมีสีที่สนใจมากกว่า 1 สีจึงประยุกต์เทคนิคนี้สำหรับการแบ่งข้อมูลของค่าสีที่มีลักษะเหมือนกันให้อยู่ข้อมูลกลุ่มเดียวและนำข้อมูลไปประยุกต์ใช้ต่อ โดยข้อมูลที่อยู่ภายในของแต่ละ cluster จะมีผลลัพธ์ที่ระยะห่างใกล้เคียงกับ means ของ cluster นั้นๆซึ่งในการทำงานจะประกอบไปด้วย 2 ขั้นตอนดังนี้

1) Assignment step คือการกำหนดจุดตั้งต้น และหาค่า Euclidean distance ของแต่ละตัวเทียบกับจุดตั้งต้นโดยใช้ค่าที่น้อยที่สุด

$$S_i = argmin \sum_{i=1}^{k} \sum_{x \epsilon S_i} ||\vec{X} - \vec{\mu}_i||^2$$

2) Update step คือการคำนวนค่า centroids ใหม่ของแต่ละ cluster โดยแบ่งข้อมูลแต่ละ cluster เพื่อนำไปสร้าง distribution ของแต่ละแม่สีที่มีความแตกต่างกันโดยมีสมการดังนี้

$$\vec{\mu}_i = \frac{1}{|S_i|} \sum_{x \in S_i} \vec{X}$$

โดยที่ S_i คือค่าที่จัดอยู่ใน cluster ต่างๆ เมื่อคำนวณจากค่าระยะห่าง Euclidean เทียบกับ mean ของแต่ละ cluster $\vec{X}$ คือค่าเวกเตอร์ใน d มิติ $\vec{\mu}_i$ คือค่าเฉลี่ยของ centroids ของแต่ละ cluster และ K คือจำนวน cluster ที่ต้องการแบ่ง

3. ระเบียบวิธีการวิจัย (Methodology)

ทางคณะผู้จัดทำได้ออกแบบและจัดทำ System architecture สำหรับระบบติดตามบริเวณที่มีลักษณะเหมือนกันดังนี้

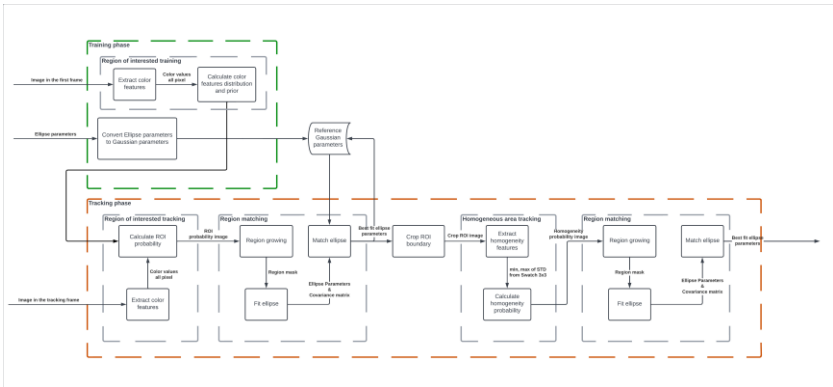

รูปที่ 1 System architecture

3.1 Region of interested tracking

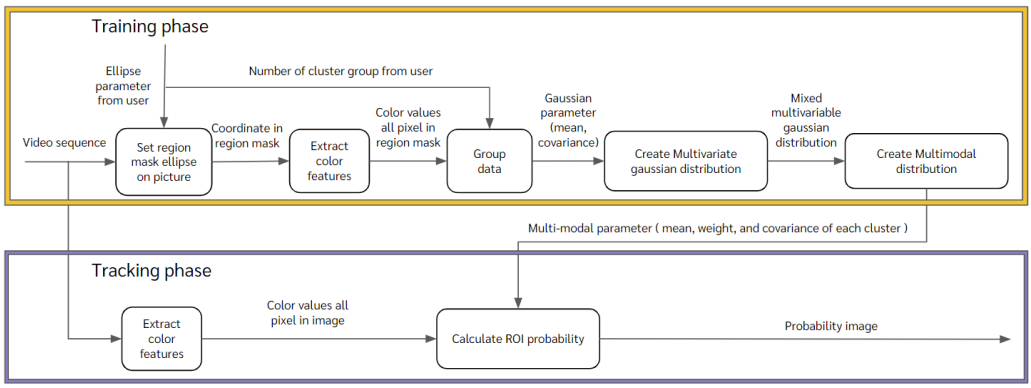

รูปที่ 2 System Architecture ของ Region of interested tracking

ระบบการติดตามบริเวณที่สนใจโดยใช้คุณสมบัติของสีมี ROI tracking process ดังรูปภาพ 2 โดยมี input คือ video sequence บริเวณที่สนใจและจำนวน cluster โดยใน training phase จะนำเฟรมแรกของวิดิโอ มาทำการดึงค่าสี และประยุกต์ใช้ k-mean clustering สำหรับการแบ่งกลุ่มข้อมูลตามจำนวนที่ user provided และทำการคำนวณ multimodal parameters สำหรับนำไปใช้ในการติดตามบริเวณ ในขั้นตอนของการ tracking จะทำการ extract color features ในทุก pixels ของภาพมาคำนวณความน่าจะเป็นโดยใช้ Multimodal parameters ที่คำนวณเอาไว้ใน training phase โดยการทำงานประกอบไปด้วยดังนี้

1. Set region mask ellipse on picture: นำ ellipse parameters มาคำนวณหา coordinate ของบริเวณที่สนใจ และบริเวณที่ไม่สนใจ เพื่อนำไปใช้ต่อในการ extract color features
2. Extract color features: ทำการดึงข้อมูลของค่าสี RGB บนภาพโดยแบ่งออกเป็นสองกลุ่มคือ บริเวณที่สนใจ และบริเวณที่ไม่สนใจ ตาม coordinate จากการ set region mask ellipse on picture
3. Group data: นำข้อมูลค่าสีของบริเวณที่สนใจ และจำนวน cluster ที่ user กำหนด ไปประยุกต์ใช้ k-means algorithms เพื่อทำการจัดกลุ่มข้อมูลในแต่ละ cluster

4. Create Multivariate gaussian distribution: นำข้อมูลในแต่ละ cluster จาก K-mean clustering มาคำนวนหา Gaussian parameters ซึ่งประกอบไปด้วย mean กับ covariance ของแต่ละ cluster และนำ Gaussian parameters ไปประยุกต์ใช้กับการคำนวณ Multivariate Gaussian distributions ของแต่ละ cluster ตามสมการที่ 2.2
5. Create Multimodal distribution: ประยุกต์ใช้สมการ multimodal distribution สำหรับรวม multivariate Gaussian distribution ของแต่ละ cluster ให้เป็น multimodal distribution โดย parameters ประกอบไปด้วย P คือค่า weight ของ cluster นั้นๆเมื่อเทียบกับจำนวนข้อมูลของของสีแต่ละ cluster ต่อจำนวนของสีทั้งหมดในบริเวณที่สนใจ และ $g(x)$ คือ multivariate Gaussian distribution ของแต่ละ cluster เพื่อนำ multimodal distribution ไปประยุกต์ใช้กับสมการของ Bayesian learning
6. Calculate ROI probability: รับข้อมูลค่าสี RGB ของทุก pixels ใน tracking image มาคำนวณหาความน่าจะเป็นโดยใช้ multimodal parameter ที่ถูกคำนวณใน training phase ซึ่งได้แก่ likelihood ของบริเวณที่สนใจ และบริเวณที่ไม่สนใจโดยใช้ probability density function ซึ่ง output ของระบบคือ probability image ที่บ่งบอกความน่าจะเป็นในการเป็นบริเวณที่สนใจในแต่ละ pixels

3.2 Region matching

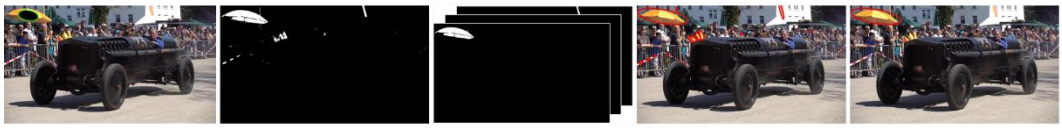

a) Source image with reference ellipse | b) Probability image | c) Candidate region | d) Fit ellipse on candidate region | e) Best fit ellipse

รูปที่ 3 ผลลัพธ์ของระบบ region matching

ระบบ Region matching ทำหน้าที่ในการ match ความเหมือนกันของแต่ละพื้นที่โดยมี reference จากเฟรมที่ n-1 ดังรูปที่ 3a. โดย input ของระบบคือ probability image ดังรูปที่ 3b. โดยแบ่งเป็น 3 ขั้นตอนคือการแบ่งกลุ่ม region นำแต่ละกลุ่มของ region มาทำการ fit ellipse และนำ ellipse parameters มาหาความเหมือนกันด้วยมาตรวัดทางสถิติ

3.2.1 Segmentation and region separation

นำ probability image ดังรูปที่ 3b. มาทำการ segmentation โดยการทำ region growing ซึ่งเป็นการแบ่งกลุ่ม region โดยการ search หาใน 8 neighbor pixel เมื่อ pixel เหล่านั้นผ่าน criteria หมายความว่า pixel นั้นเป็น region เดียวกันโดยพารามิเตอร์ที่สำคัญของการทำ region growing คือ criteria threshold และ initial seed โดยในโครงงานนี้จะประยุกต์ใช้สมการ Otsu's thresholding ในการหาพารามิเตอร์ของการทำ Region growing ซึ่งผลลัพธ์ที่ได้จะออกมาเป็น candidate region ดังรูป 3c.

3.2.2 Fitting ellipse

ทำการ fit ellipse โดยนำ candidate region ดังรูป 3c. คำนวณ weighted mean และ weighted variance ซึ่งมองความน่าจะเป็นคือ weight ของแต่ละ pixel โดย weighted mean คือจุดศูนย์กลางของวงรี และนำ weighted variance มาสร้าง covariance matrix เพื่อนำไปแยก components หา eigenvector และ eigenvalue โดยค่าของ eigenvalue ใช้สำหรับการหา major radius และ minor radius และ eigenvector สำหรับการหาองศาของการหมุนของวงรี โดยในขั้นตอนนี้จะได้พารามิเตอร์ของวงรีมาจำนวนเท่ากับจำนวนของ candidate region ดังภาพที่ 3d.

3.2.3 Matching ellipse

นำพารามิเตอร์ของวงรีของแต่ละ region ไปทำการ matching กับ reference parameters ที่ได้ทำการเก็บข้อมูลและอัพเดทของเฟรม n-1 โดยประยุกต์ใช้คุณสมบัติของวรีเพื่อสร้างเป็น score ดังต่อไปนี้

1) Center score: นำ candidate ellipse center มาหาค่า Euclidean distance เทียบกับ reference ellipse center จากนั้นทำการ normalize เพื่อปรับช่วงของ distance ให้อยู่ในช่วง 0 ถึง 1 และสร้างเป็น center score โดยใช้สมการ center score = 1 – distance ซึ่ง score ที่สูงแสดงถึงความใกล้เคียงของ ellipse center กับ reference
2) Radius score: นำ candidate radius vector มาหาค่า Euclidean distance เทียบกับ reference radius vector จากนั้นทำการ normalize เพื่อปรับช่วงของ distance ให้อยู่ในช่วง 0 ถึง 1 และสร้างเป็น radius score โดยใช้สมการ radius score = 1 – distance ซึ่ง score สูงแสดงถึงความใกล้เคียงของ ellipse radius vector กับ reference

3) Rotation angle score: ใช้สมการ cosine similarity $= \frac{\vec{r}_{ref} \cdot \vec{r}_{cand}^{T}}{\|\vec{r}_{ref}\| \|\vec{r}_{cand}\|}$ โดยที่ $\vec{r} = [r_1 \cos(\theta), r_2 \cos(\theta)]^T$ และ θ คือ rotation angle ของ ellipse ซึ่งเมื่อ Rotation angle score มีค่าอยู่ในช่วง 0 ถึง 1 โดยเมื่อ score เข้าใกล้ 1 มากแสดงถึงความเหมือนกันของ rotation angle กับ reference

หลังจากทำการคำนวณ score ทั้ง 3 ส่วนนำ score ทั้งหมดมาคูณด้วย weight เพื่อปรับใช้ในแต่ละ scenario ของการ tracking โดยผลลัพธ์จะออกมาเป็นพารามิเตอร์ของวงรีที่มีความใกล้เคียงกับ reference parameters มากที่สุดดังภาพ 3e.

3.3. Homogeneous area tracking

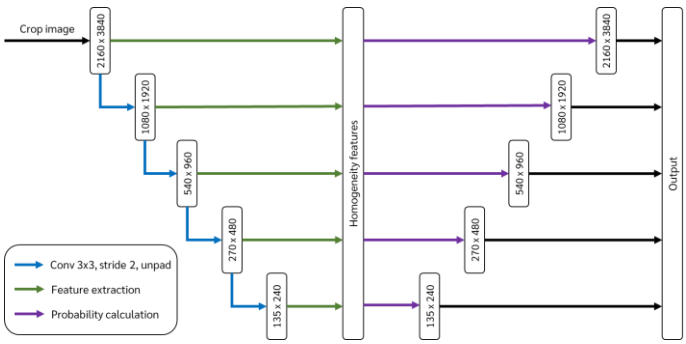

รูปที่ 4 แผนภาพสถาปัตยกรรมระบบตรวจจับความเป็นเนื้อเดียวกัน

ระบบติดตามพื้นที่ที่มีความเป็นเนื้อเดียวกันประยุกต์ใช้หลักการ Gaussian image pyramid เพื่อวิเคราะห์คุณลักษณะแบบ multi resolution ในแต่ละชั้นของ pyramid ถูกจำแนกคุณลักษณะความเป็นเนื้อเดียวกันและคำนวณความน่าจะเป็นของความเป็นเนื้อเดียวกันด้วยหลักการของเบย์ เพื่อให้ได้ออกมาเป็น homogeneity probability image ซึ่งแสดงถึงความน่าจะเป็นที่จะเป็นเนื้อเดียวกันในแต่ละ pixel

1. Gaussian image pyramid: ทำการ convolve ภาพด้วย Gaussian kernel ขนาด 3x3 stride 2 ซึ่งจะทำให้ขนาดภาพในแต่ละชั้นของ pyramid มีขนาดที่ต่ำลงครึ่งหนึ่ง ในขณะเดียวกันขั้นตอนของการ slide window ก่อนทำการ convolve ทำให้เราสามารถหาค่า standard deviation ของข้อมูลกลุ่มข้อมูลขนาด 3x3 เพื่อเก็บเป็น buffer นำไปใช้ต่อในขั้นตอน feature extraction
2. Homogeneous features extraction: จาก buffer array ที่ได้จาก Gaussian image pyramid ทำให้เราได้ buffer ทั้งหมดสองตัวคือ ภาพที่มีขนาดต่างกัน และstandard deviation image อย่างละ 5 ภาพ ในโครงงานนี้ใช้ค่าต่ำสุดและมากสุดของ standard deviation ของพื้นที่ 3x3 โดยทำการ sliding window ขนาด 3x3, padding left 1, padding right 1 และ 1 stride เพื่อ represent ความเป็นเนื้อเดียวกันในแต่ละ pixel นั้นๆ ซึ่งคุณลักษณะที่มีความเป็นเนื้อเดียวกันค่า SD ของพื้นที่จะมีค่าต่ำเข้าใกล้ศูนย์ ในทางกลับกันหากเป็นพื้นที่ที่ไม่เป็นเนื้อเดียวกัน จะมีค่า SD ที่สูงตามความแตกต่างของ foreground and background
3. Homogeneous probability calculation: จากคุณลักษณะที่ได้จาก homogeneous feature extraction ในแต่ละขั้นของ pyramid นำมาคำนวณหาความน่าจะเป็นที่ในแต่ละ pixel จะมีความเป็นเนื้อเดียวกันโดยใช้ข้อมูลทางสถิติที่ถูกเรียนรู้มาก่อนหน้าเพื่อสร้าง probability image ในแต่ละขั้นของ pyramid โดยข้อมูลทางสถิติที่ถูกเรียนรู้ก่อนหน้า

รูปที่ 5 homogeneous probability image ในแต่ละ resolution โดยภาพซ้ายสุดคือความละเอียดสูงที่สุด และภาพทางขวาสุดคือความละเอียดต่ำสุด

input ของระบบ homogeneous area tracking คือ image ที่ทำการ crop เฉพาะ area ที่สนใจจาก ellipse ที่ represent ถึงบริเวณที่สนใจขเพื่อลด computational time จากนั้นจึงทำการ tracking homogeneous area ซึ่งผลลัพธ์ออกมาเป็น homogeneity probability image หรือความน่าจะเป็นที่มีความเป็นเนื้อเดียวกันในแต่ละ pixel ดังรูปภาพที่ 5 โดยในแต่ละภาพแสดงถึงความน่าจะเป็นที่ออกมากจาก pyramid ในแต่ละ level หรือทำการ tracking ในแต่ละ resolution โดยภาพซ้ายสุดคือความละเอียดสูงที่สุด และภาพทางขวาสุดคือความละเอียดต่ำสุด โดยค่า homogeneity probability image จะถูกนำไปใช้ในการหา sub features ของบริเวณที่สนใจในอนาคต

4. การทดลอง (Experiment)

4.1 Performance testing

4.1.1 Perspective change

รูปที่ 6 train video frame 0

รูปที่ 7 train video frame 31

รูปที่ 8 train video frame 51

รูปที่ 9 probability image frame 0

รูปที่ 10 probability image frame 31

รูปที่ 11 probability image frame 51

การทดสอบในกรณีที่มีการเปลี่ยนแปลงมุมมองของกล้องโดยใช้ train video จาก DAVIS dataset โดยรูปที่ 6, 7 และ 8 แสดงถึงภาพต้นฉบับในเฟรมที่ 0, 31 และ 51 ตามลำดับ โดยบริเวณที่สนใจในในการทดลองนี้คือบริเวณป้ายทางด้านขวามือของภาพ ซึ่งระนาบของบริเวณที่สนใจในภาพข้างต้นมีการเปลี่ยนแปลงจากเฟรมแรก เมื่อระบบ ROI tracking ทำการติดตามพื้นที่ได้ probability image ดังภาพ 9 – 11 แสดงถึงความสามารถในการติดตามที่ลดลงเมื่อมุมมองกล้องเปลี่ยนแปลง โดยเมื่อถึง frame ที่ 51 พบว่าระบบ ROI tracking ไม่สามารถแสดงให้เห็นถึงบริเวณที่สนใจได้

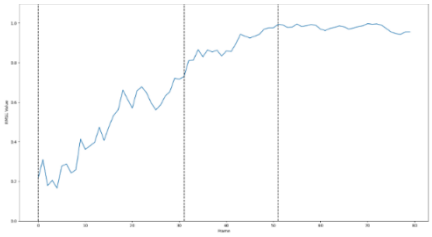

รูปที่ 12 Probability evaluation result of train dataset

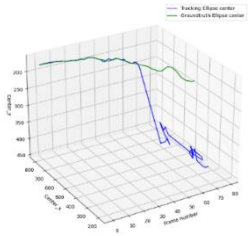

รูปที่ 13 Ellipse evaluation result of train dataset

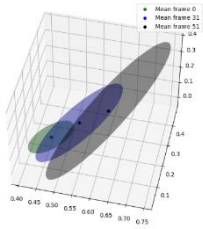

รูปที่ 14 Ellipsoid plot of ROI area at frames 0, 31, 51

จากภาพข้างต้นแสดงให้เห็นถึงประสิทธิภาพในการติดตามของระบบที่ต่ำลงในทุก frame โดยรูปที่ 12 แสดงค่า RMSE ของ probability image เทียบกับ ground truth ในทุกเฟรมซึ่งแสดงถึงแนวโน้มที่เพิ่มขึ้นของความคิดพลาดในการตรวจจับ เมื่อถึงเฟรมที่ 51 ค่า RMSE เพิ่มขึ้นจนเกือบถึง 1 กล่าวคือไม่มี pixel ใดในบริเวณที่สนใจมีค่าความน่าจะเป็นที่ถูกต้อง นอกจากนี้ภาพที่ 13 แสดง ellipse center ของระบบ และ ground truth ซึ่งพบว่าก่อนเฟรม 51 ระบบสามารถติดตามโดยมีความผิดพลาดใน ellipse center สูงสุดเพียง 3.918 pixels แต่เมื่อบริเวณที่สนใจไม่สามารถทำการติดตามได้ทำให้ความผิดพลาดใน ellipse center สูงมากถึง 258 pixels สาเหตุข้างต้นเกิดจาก variation ของบริเวณที่เราสนใจมีเพิ่มมากขึ้น สังเกตได้จากรูปที่ 14 ซึ่งทรงรีสีเขียว สีน้ำเงิน และสีดำ แสดงให้เห็นถึงข้อมูลของค่าสีใน frame 0, 31 และ 51 ตามลำดับ ซึ่งยิ่งมีการเปลี่ยนแปลงของมุมมองกล้องข้อมูลบริเวณที่สนใจยิ่งมีการเปลี่ยนแปลงมากขึ้น โดยข้อมูลในเฟรมที่ 31 และ 51 มี Euclidean distance ของจุดศูนย์กลางหรือค่าเฉลี่ยของข้อมูลสีในบริเวณที่สนใจ เทียบกับเฟรมที่ 0 หรือเฟรมที่ใช้ในการเรียนรู้ 0.10 และ 0.197 ตามลำดับ

4.1.2 Light variation

รูปที่ 15 Light variation video frame 58

รูปที่ 16 Light variation video frame 59

รูปที่ 17 Probability image frame 59

รูปที่ 18 Probability image frame 59

การทดสอบนี้คณะผู้จัดทำทดสอบความสามารถในการติดตามพื้นที่ในกรณีที่มีการเปลี่ยนแปลงของแสงอย่างกะทันหันโดยภาพที่ 15 คือภาพก่อนที่มีการเปลี่ยนแปลงของแสง และภาพที่ 16 คือภาพที่มีการเปลี่ยนแปลงของแสง เมื่อระบบ ROI tracking ทำการติดตามพื้นที่ได้ผลลัพธ์เป็นภาพ probability image ดังรูปที่ 17 และ 18 แสดงให้เห็นถึงความสามารถในการติดตามพื้นที่ที่ลดลงเมื่อเกิดการเปลี่ยนแปลงของแสงอย่างกะทันหัน

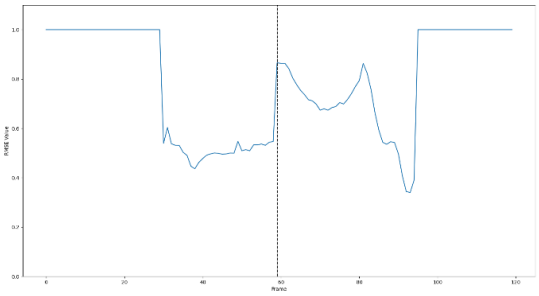

รูปที่ 19 Probability evaluation result light dataset

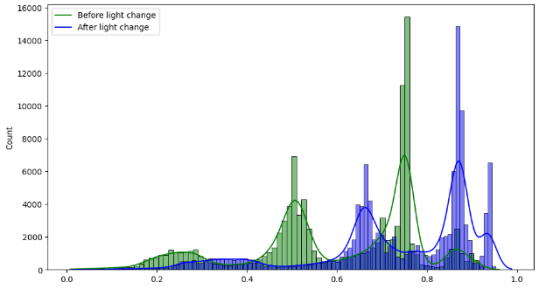

รูปที่ 20 Histogram plot of ROI luminance values

รูปที่ 19 แสดง Probability evaluation result จะพบการเพิ่มขึ้นของ error อย่างเห็นได้ชัดที่เฟรม 59 หรือเป็นเฟรมที่มีการเปลี่ยนแปลงของแสงอย่างกระทันหันโดยมีค่า error ที่เพิ่มขึ้นจากเฟรม 58 ไปเฟรม 59 คือ 0.5247 เป็น 0.8584 โดยค่าที่เพิ่มขึ้นอยู่ที่ 0.3337 ซึ่งสาเหตุที่ทำให้เกิดการเพิ่มขึ้นของค่า RMSE เมื่อเทียบกับ ground truth สามารถแสดงให้เห็นดังรูปที่ 20 โดยบริเวณที่เราสนใจเป็นบริเวณที่มีลักษณะเป็นสีขาวและดำทางผู้จัดทำจึงทำการแสดงข้อมูลด้วยความเข้มของแสง โดยจะพบว่าเมื่อเกิดการเปลี่ยนแปลงของแสงค่า luminance ของบริเวณที่สนใจมีการเพิ่มขึ้น โดยปัญหาข้างต้นทางผู้จัดทำเล็งเห็นถึงการประยุกต์ใช้ homogeneous area tracking ในการทำการทดลองโดยผลลัพธ์ที่ได้ออกมาดังนี้

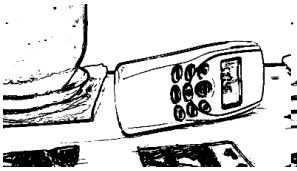

รูปที่ 21 Homogeneous probability image frame 58

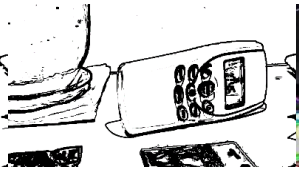

รูปที่ 22 Homogeneous probability image frame 59

รูปที่ 23 Sub features tracking frame 58

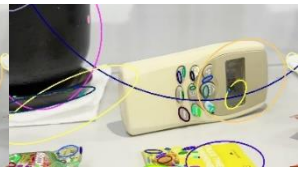

รูปที่ 24 Sub features tracking frame 59

จากรูปที่ 21 และ 22 แสดงให้เห็น homogeneous probability image เมื่อมีการเปลี่ยนแปลงของแสงยังคงแสดงให้เห็นถึงพื้นที่ที่เป็นบริเวณที่สนใจ อีกทั้งยังแสดงให้เห็นถึงความสามารถของการติดตาม sub features ที่บริเวณปุ่มของรีโมตเนื่องจากมีการเปลี่ยนแปลงของความน่าจะเป็นที่ต่ำ เมื่อนำ homogenous probability image มาทำการติดตาม sub features ได้ผลลัพธ์ดังภาพที่ 23 และ 24 ซึ่งจะพบว่าที่บริเวณ sub features ของบริเวณพื้นที่สนใจสามารถติดตามได้แม้ว่ามีการเปลี่ยนแปลงของแสงอย่างกระทันหันซึ่งเป็นแนวทางหนึ่งในการพัฒนาระบบ ROI tracking

4.1.3 Occlusion

รูปที่ 25 Source image before occlusion

รูปที่ 26 Source image when occlusion

รูปที่ 27 Source image after occlusion

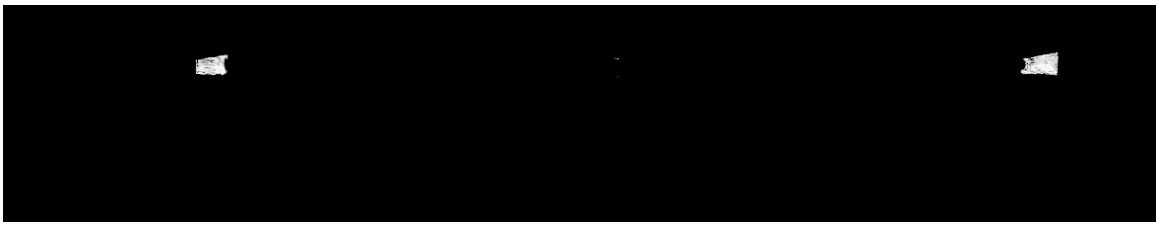

รูปที่ 28 Probability image before occlusion รูปที่ 29 Probability image when occlusion รูปที่ 30 Probability image after occlusion

การทดสอบนี้คณะผู้จัดทำต้องการที่จะทดสอบความสามารถในการติดตามพื้นที่ในกรณีที่บริเวณที่สนใจมีการบดบัง โดยบริเวณที่สนใจคือบริเวณกำแพงสีเหลืองซึ่งมีความ unique ทางด้านสีของพื้นที่แต่เกิดการบดบังจาก dynamic object ซึ่งระบบติดตามบริเวณที่สนใจในการทดสอบนี้ให้ประสิทธิภาพที่สูงแต่เมื่อมีการบดบังของวัตถุทำให้ประสิทธิภาพในการติดตามลดลงอย่างเห็นได้ชัด

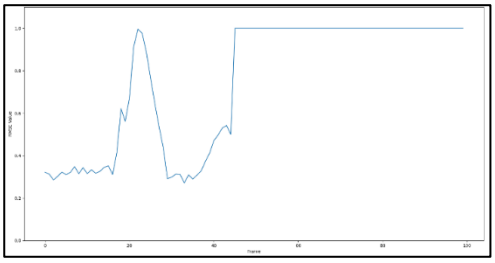

รูปที่ 31 Probability evaluation result

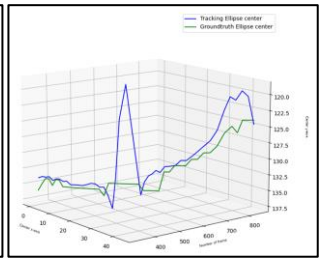

รูปที่ 32 Ellipse evaluation result

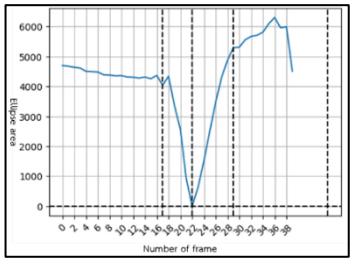

รูปที่ 33 Ellipse area of each frame

รูปที่ 31 และ 32 แสดงให้เห็นถึงการ evaluation ค่า probability และ ellipse center เปรียบเทียบกับ ground truth ตามลำดับ เมื่อเกิดการ occlusion ค่า error ของทั้งสองกราฟสูงขึ้นอย่างเห็นได้ชัด โดยก่อนที่บริเวณที่สนใจจะถูกบดบังค่า RMSE อยู่ที่ 0.3226 และความผิดพลาดของ ellipse center มีค่าสูงสุดเพียง 2.71 pixels แต่เมื่อเกิดการบดบังขึ้นค่า RMSE เพิ่มขึ้นถึง 0.7025 และ ellipse center เกิดข้อผิดพลาดสูงถึง 32.426 pixels แต่หลังจากนั้นระบบสามารถติดตามได้อย่างถูกต้องเนื่องจากความโดดเด่นของบริเวณที่สนใจ ซึ่งในเคสนี้ทางผู้จัดทำเล็งเห็นถึงการประยุกต์ใช้ ellipse parameter เข้ามาช่วยในการตรวจจับการ occlusion เพื่อให้มนุษย์เข้ามามีส่วนรวมในการตัดสินใจดังรูปที่ 33 แสดงพื้นที่ของวงรีที่ติดตามได้ เมื่อบริเวณที่สนใจเริ่มมีการบดบังดังเฟรมที่ 17 ถึง 21 พื้นที่ของวงรีที่ทำการติดตามลดลงจนกระทั่งเหลือ 0 ในเฟรมที่ 22 ซึ่งบริเวณที่สนใจถูกบดบังจนไม่สามารถติดตามได้ ซึ่งเป็นสัญญาณหนึ่งที่ช่วยให้การตรวจจับการ occlusion

4.2 Robustness testing

4.2.1 ROI ellipse size

รูปที่ 34 Source image with 70% area

รูปที่ 35 Source image with 100% area

รูปที่ 36 Source image with 130% area

รูปที่ 37 Source image with 70% area

รูปที่ 38 Source image with 100% area

รูปที่ 39 Source image with 130% area

ทางคณะผู้จัดทำเลือกบริเวณที่สนใจสำหรับ training ที่มีขนาดที่ต่างกันโดยประกอบไปด้วยการเลือกบริเวณที่สนใจ 70% 100% และ 130% และนำไปสร้าง probability image ด้วย testing image จากระบบของ ROI tracking และเปรียบเทียบกับ ground truth ที่คณะผู้จัดทำสร้างขึ้นมาซึ่งทดสอบกับ video sequence ทั้ง 2 ประเภทคือ 1.วิดีโอ train เป็นวิดีโอที่บริเวณที่สนใจมีลักษณะที่โดดเด่นและแตกต่างจากบริเวณพื้นหลัง 2.วิดีโอ light variation เป็นวิดีโอที่บริเวณที่สนใจมีลักษณะที่เหมือนกับบริเวณพื้นหลัง

รูปที่ 40 Source image with 70% area

รูปที่ 41 Source image with 100% area

รูปที่ 42 Source image with 130% area

รูปที่ 43 Probability image with 70% area

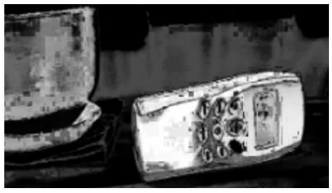

รูปที่ 44 Probability image with 100% area

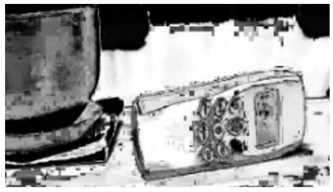

รูปที่ 45 Probability image with 130% area

ผลลัพธ์ในรูปที่ 40 ถึง 45 แสดง probability image ซึ่งประกอบไปด้วยการเลือกบริเวณที่สนใจสำหรับ training ที่มีขนาดที่ต่างกันโดยมีผลลัพธ์ปรากฏดังนี้ เมื่อเลือกบริเวณที่สนใจ 130% probability image ที่ปรากฏทั้ง 2 ชุดมูล จะมีบริเวณที่ไม่เกี่ยวข้องกับบริเวณ ROI ปรากฏขึ้นซึ่งส่งผลต่อ matching algorithms สำหรับการแบ่งบริเวณ ROI แต่หากเลือกบริเวณที่สนใจ 70% probability image ที่ปรากฏทั้ง 2 การทดสอบจะมีบริเวณ ROI ที่น้อยกว่าปรากฏขึ้นเมื่อเปรียบเทียบกับการเลือกบริเวณที่สนใจ 100% โดยเราจะดูผลลัพธ์ความแตกต่างด้วยการเปรียบเทียบกับ ground truth ดังผลลัพธ์ดังนี้

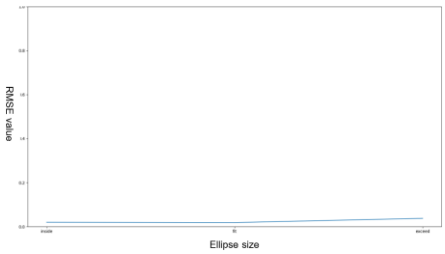

รูปที่ 46 Probability evaluation result of train dataset

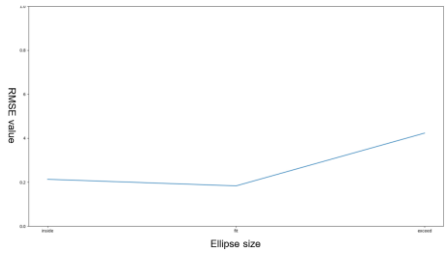

รูปที่ 47 Probability evaluation result light of variation dataset

ผลลัพธ์ในรูปที่ 46 และ 47 แสดงการเปรียบเทียบความแตกต่างระหว่าง probability image เมื่อคณะผู้จัดทำทำการเลือกบริเวณที่สนใจสำหรับ training มีขนาดที่แตกต่างกันโดยนำเทียบกับ ground truth ซึ่งเปรียบเทียบด้วยค่า RMSE ได้ผลลัพธ์ดังนี้เมื่อคณะผู้จัดทำทำการเลือกบริเวณที่สนใจ 130% ส่งผลให้ค่า RMSE มีการเพิ่มขึ้นจาก 0.0014 เป็น 0.0376 และ 0.1791 ถึง 0.4232 ซึ่งเป็นการเพิ่มขึ้น 26 และ 2 เท่าบนชุดข้อมูลวิดีโอ train และชุดข้อมูลของวิดีโอ light variation ตามลำดับ ซึ่งผลลัพธ์นี้บ่งบอกว่าระบบไม่มีความคงทนต่อการเลือกบริเวณที่สนใจ 130% แต่ในทางตรงกันข้ามระบบจะมีประสิทธิภาพดีขึ้นเมื่อเลือกบริเวณที่สนใจ 100% หรือขนาดพื้นที่พอดีกับบริเวณ ROI แต่ถ้าเกิดเลือกบริเวณที่น้อยเกินไปจะส่งผลให้ค่า RMSE มีค่ามากขึ้นซึ่งเป็นค่า error เมื่อเทียบกับ ground truth เปรียบเสมือนการเลือกบริเวณที่สนใจ 70%

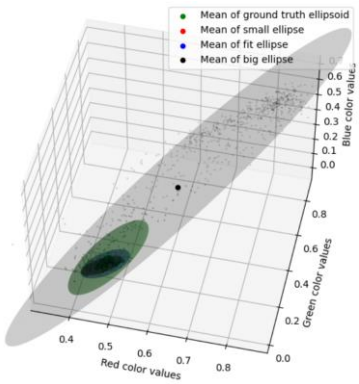

รูปที่ 48 Ellipsoid of train dataset

รูปที่ 48 แสดงผลลัพธ์ของชุดข้อมูลวิดีโอ train แสดงถึงทรงรีที่แสดงถึงข้อมูลของบริเวณที่สนใจสำหรับการเลือกขนาดของวงรีในแต่ละแบบโดยทรงรีสีน้ำเงิน สีเขียว และสีดำ แสดงถึงการเลือดบริเวณที่สนใจขนาด 70% 100% และ 130% ตามลำดับ ซึ่งทรงรีของการเลือกบริเวณที่สนใจ 70% จะมีค่าความแปรปรวนที่น้อยกว่า ground truth ซึ่งจะไม่ครอบคลุมข้อมูลที่เป็นบริเวณ ROI และทำให้ probability image ที่ปรากฏออกมามีลักษณะความน่าจะเป็นที่น้อยลงบริเวณที่สนใจ แต่ถ้าเป็นการเลือกบริเวณที่สนใจ 130% จะไปครอบคลุมข้อมูลบริเวณภายนอก ROI ซึ่งจะส่งผลต่อข้อมูล weight ของ ROI ทำให้ประสิทธิภาพของระบบลดลง

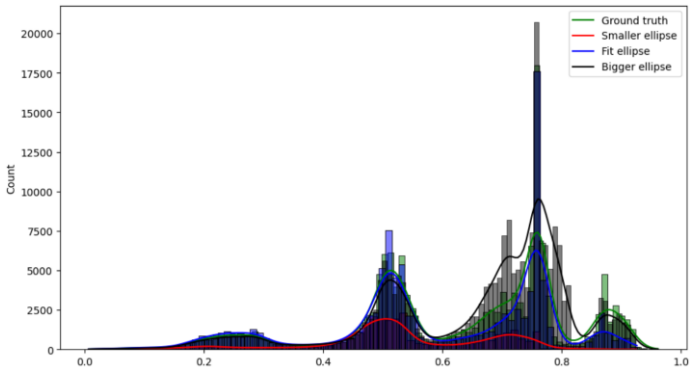

รูปที่ 49 Histogram of luminance of light dataset

รูปที่ 49 แสดงผลลัพธ์ของชุดข้อมูลวิดีโอ light variation ซึ่งสามารถแสดงผลลัพธ์ถึงสาเหตุที่ทำให้เกิดการเพิ่มขึ้นของ error เมื่อเทียบกับ ground truth สามารถแสดงให้เห็นได้ดังภาพด้านบน โดยบริเวณที่เราสนใจเป็นบริเวณที่มีลักษณะเป็นสีขาวและดำทางผู้จัดทำจึงทำการแสดงข้อมูลของความเข้มแสงดังภาพ 49 โดยจะพบว่าเมื่อคณะผู้จัดทำทำการเลือกบริเวณที่สนใจ 130% จะสังเกตได้ว่ามีข้อมูลที่ไม่จำเป็นที่เกิดขึ้นเมื่อเทียบกับ ground truth ทำให้เป็นสาเหตุที่ probability image ปรากฏบริเวณที่ไม่ใช่ ROI จึงทำให้เมื่อเทียบกับ ground truth ค่า error สูงขึ้นแต่ถ้าคณะผู้จัดทำทำการเลือกบริเวณที่สนใจ 70% จะสังเกตได้ว่ามีข้อมูลไม่เพียงพอเมื่อเทียบกับ ground truth ทำให้เป็นสาเหตุที่ probability image ปรากฏบริเวณที่เป็น ROI จำนวนน้อยจึงทำให้เมื่อเทียบกับ ground truth ค่า error สูงขึ้นและถ้าคณะผู้จัดทำทำการเลือกบริเวณที่สนใจ100% ก็จะมีข้อมูลที่ใกล้เคียงกับ ground truth มากที่สุดและ probability image ที่ออกมาใกล้เคียงกับ ground truth มากที่สุด

4.2.2 Number of cluster

รูปที่ 50 Source image frame 58

รูปที่ 51 Source image frame 59

การทดสอบความคงทนของระบบเมื่อคณะผู้จัดทำทำการเลือกจำนวนของ cluster ที่มีความคลุมเครือโดยอ้างอิง cluster หลักจากสีที่ปรากฏขึ้นในบริเวณที่สนใจ ในสถานการจริงบริเวณที่สนใจบางครั้งมีจำนวนสีที่โดดเด่นไม่ชัดเจนถ้าให้ผู้ใช้งานทำการเลือกจำนวน cluster ตามสีที่ปรากฏอาจจะไม่ครอบคลุมและมีความคลุมเครือกับสีทั้งหมดที่ปรากฏขึ้น ดังนั้นทางคณะผู้จัดทำทำการทดสอบกับวิดีโอ first light และแบ่งการทดสอบออกเป็น 2 เคสคือ 1.ก่อนที่จะมีการเปลี่ยนแปลงของแสงกะทันหัน 2.หลังจากที่มีการเปลี่ยนแปลงของแสงกะทันหัน โดยเลือกบริเวณที่สนใจในรูปภาพ training และเลือกจำนวน cluster ที่มีความคลุมเครือและไม่ชัดเจนตั้งแต่ n-2 ถึง n+2 โดย n คือจำนวน cluster ที่ถูกต้อง จากนั้นนำไปประยุกต์ใช้กับระบบ Region of interested tracking กับรูปภาพ testing สำหรับสร้าง probability image เพื่อนำไปเปรียบเทียบกับ ground truth

รูปที่ 52 ผลลัพธ์ probability image เมื่อคณะผู้จัดทำทำการใส่ cluster ตั้งแต่ 5,6,7,8,9 ก่อนแสงเปลี่ยนกะทันหัน

รูปที่ 53 ผลลัพธ์ probability image เมื่อคณะผู้จัดทำทำการใส่ cluster ตั้งแต่ 5,6,7,8,9 หลังแสงเปลี่ยนกะทันหัน

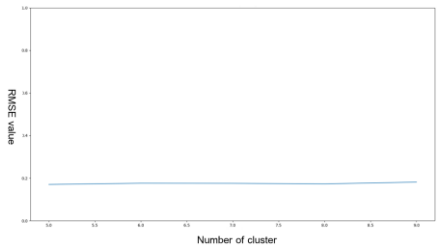

รูปที่ 54 Probability evaluation result before light change

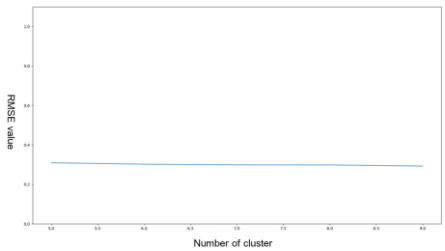

รูปที่ 55 Probability evaluation result after light change

ผลลัพธ์ในรูปที่ 54 และ 55 แสดงการเปรียบเทียบความแตกต่างระหว่าง probability image เทียบกับ ground truth ก่อนแสงเปลี่ยนและเคสหลังแสงเปลี่ยนตามลำดับ โดยการเปรียบเทียบด้วย loss function RMSE (Root mean square error) ซึ่งคณะผู้จัดทำสังเกตเห็นสีที่ปรากฏในบริเวณที่สนเป็นสีที่โดดเด่น 7 สีดังนั้นผู้จัดทำจึงได้เลือก 7 cluster เป็นตัวตั้งต้น จะสังเกตุได้ว่าข้อผิดพลาดไม่มีการเปลี่ยนแปลงอย่างมีนัยสำคัญ เมื่อผู้ใช้เลือก cluster ในจำนวนที่คลุมเครือและไม่เหมาะสมภายในช่วงที่ไม่ชัดเจนในช่วง 5 – 9 clusters โดยดูจากผลลัพธ์การเปรียบเทียบจะมีค่า error

อยู่ในช่วง 0.1703 ถึง 0.1813 ของเคสก่อนแสงเปลี่ยนและเคสหลังแสงเปลี่ยนค่า error อยู่ในช่วง 0.2918 ถึง 0.3084 ซึ่งแสดงให้เห็นว่ามีค่า error นั้นแตกต่างกันน้อยมากๆ ดังนั้นผลลัพธ์นี้บ่งชี้ว่าระบบมีความทนทานต่อจำนวน cluster ที่ไม่เหมาะสม

4.3 Runtime testing

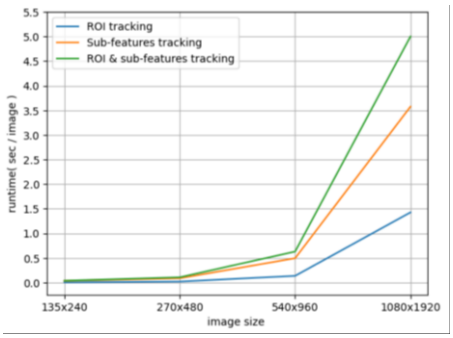

รูปที่ 56 ผลลัพธ์การทำงานของระบบประกอบไปด้วย ROI tracking module และ Sub-feature tracking module

การทดสอบเวลาการทำงานของระบบคือการทดสอบระยะเวลาที่ระบบใช้ในการทำงานเฉลี่ยต่อ 1 รูปภาพโดยทำการทดสอบทั้งหมด 30 ภาพ โดยจะทดสอบด้วย laptop Lenovo V15 G3 IAP with a 12th Gen Intel® Core™ i3-1215U CPU. โดยรูปที่ 56 แสดงเวลาการทำงานของระบบด้วยขนาดภาพที่แตกต่างกัน โดยคณะผู้จัดทำทำทำแบ่งการทดสอบออกเป็น 2 module คือ ROI tracking module โดย module นี้จะประกอบไปด้วยการทำงานของ ROI probability calculation กับ region matching และ Sub-feature tracking module โดย module นี้จะประกอบไปด้วยการทำงานของ homogeneous area tracking กับ region matching

ระยะเวลาการทำงานของระบบโดยรวมเมื่อทดสอบด้วยรูปภาพขนาด 1080p จะใช้เวลาการทำงานที่ 5 วินาทีต่อภาพ เนื่องจากระบบมีการคำนวนที่ซับซ้อน ซึ่งระยะเวลาในการทำงานส่วนใหญ่อยู่ที่ homogeneous area tracking module เนื่องจาก module นี้ประยุกต์ใช้ pyramid image structure ซึ่งจะคำนวณภาพที่ความละเอียดต่ำตัวอย่างเช่น หากรูปภาพต้นฉบับมีขนาด 1920x1920 โมดูลนี้จะคำนวณรูปภาพ 5 รูปที่มีขนาดตั้งแต่ 1920x1920, 960x960, 480x480, 240x240, และ 120x120 ส่งผลให้การทำงานของ module ใช้ระยะเวลาที่นาน และจะส่งผลต่อ sub-feature module เนื่องจากระบบรับรูปภาพที่เป็น video sequence จึงส่งผลให้โมดูลนี้มีระยะเวลาที่นานที่สุดในระบบ

5. Discussion and conclusion

จากการทดสอบระบบติดตามบริเวณที่สนใจโดยการประยุกต์ใช้ทฤษฎีของ Bayes ร่วมกับคุณลักษณะของสีความเป็นเนื้อเดียวกัน ซึ่งนำไปใช้ในการติดตามพื้นที่ที่อยู่นิ่ง มีความโดดเด่น และมีมนุษย์เข้ามาเป็นส่วนร่วมในการติดตามของระบบ โดยในโครงงานนี้ทำการทดสอบประสิทธิภาพ ความคงทนของการติดตาม และระยะเวลาในการทำงานของระบบ

ประสิทธิภาพของการติดตามใช้ค่า RMSE ของ probability image เปรียบเทียบกับ ground truth ในการวัดผล โดยในโครงงานนี้มีค่า RMSE ของการติดตามอยู่ที่ 0.7561, 0.7983 และ 0.8555 แต่ความผิดพลาดของ ellipse center แสดงให้เห็นว่าการติดตามในเคสที่ไม่มีการรบกวนจากสภาพแวดล้อม มีค่าความผิดพลาดเทียบกับ ground truth สูงสุดเพียง 4 pixels โดยในการทดสอบด้วยการทดสอบในเคส perspective change, light variation และ occlusion ตามลำดับโดยในเคสของ perspective change จะพบว่าบริเวณที่สนใจมีค่าสีที่มีการเปลี่ยนแปลงในทุกเฟรมที่มีการเปลี่ยนแปลงของมุมมองกล้องซึ่งสามารถแก้ได้ด้วยการใช้เทคนิค incremental learning ซึ่งทางผู้จัดทำได้ทำการ proof of concept ได้ผลลัพธ์ดังรูปที่ 57 โดยมีการเปรียบเทียบผลลัพธ์ความผิดพลาดก่อน แสดงด้วยเส้นสีฟ้า และหลังการทำ incremental learning แสดงด้วยเส้นสีเขียว ซึ่งทำให้ระบบมีความผิดพลาดลดลงเหลือ 0.2590 ส่วนในกรณีของ light variation dataset ในโครงงานนี้แสดงให้เห็นถึงการติดตามด้วย homogeneity features ซึ่งมีการเปลี่ยนแปลงของ probability image ที่น้อยเมื่อเทียบกับการติดตามด้วยค่าสี และในกรณีของ occlusion เราสามารถประยุกต์ใช้ matching score ในการสร้าง algorithm สำหรับการป้องกันในเคสนี้

ความคงทนของระบบติดตามในโครงงานนี้มีความคงทนต่อการเลือกจำนวน cluster ที่ไม่เหมาะสมซึ่งความแตกต่างของการเลือก cluster ที่ไม่เหมาะสมส่งผลต่อความสามารถในการติดตามเพียงไม่เกิน 0.0166 แต่ระบบติดตามไม่มีความคงทนต่อการเลือกบริเวณที่สนใจซึ่งหาก user ทำการเลือกวงรีที่มีขนาดใหญ่เกินบริเวณที่สนใจจะทำให้ระบบมีค่า RMSE เพิ่มขึ้นจาก 0.1831 เป็น 0.4232 แต่ถ้าหากเลือกวงรีที่มีขนาดเล็กกว่าบริเวณที่สนใจจะทำให้ค่าความผิดพลาดของระบบเพิ่มขึ้นเล็กน้อยแต่เมื่อเลือกวงรีที่มีขนาดเล็กลงยิ่งส่งผลให้ค่าความผิดพลาดเพิ่มมากขึ้น

ระยะเวลาในการทำงานของระบบต่อ 1 ภาพที่มีขนาด 1080p ใช้เวลา 5 วินาทีซึ่งเป็นผลมาจากการประมวลผลด้วยเทคนิค pyramid image structure แต่ด้วยการทดสอบนี้ทดสอบด้วย 12th Gen Intel® Core™ i3-1215U CPU และประมวลแบบ single processing การ optimize ด้วยการทำแบบ multithreading หรือประมวลผลด้วย GPU จึงเป็นสิ่งที่จำเป็นหากนำระบบนี้ไปใช้ต่อในอนาคต

6. กิตติกรรมประกาศ (Acknowledgement)

ทางคณะผู้จัดทำขอขอบคุณบริษัท ยานนิกซ์ จำกัด ที่สนับสนุนสถานที่การทำงานและสนับสนุนด้านเทคโนโลยีสำหรับการเรียนรู้ที่นำไปประยุกต์ใช้กับโปรเจคระบบติดตามพื้นที่โดยการประยุกต์ใช้ทฤษฎีของเบย์ประกอบไปด้วย color และ homogeneous metric และโปรเจคนี้เป็นส่วนหนึ่งที่ทางบริษัทนำไปใช้งานและเป็นแนวทางการพัฒนาต่อสำหรับการใช้งานในบริษัท ยานนิกซ์ จำกัด

7. เอกสารอ้างอิง (References)

[1] A. R. Yadav, R. S. Anand, M. L. Dewal, and S. Gupta, ‘Gaussian image pyramid based texture features for classification of microscopic images of hardwood species’, Optik, vol. 126, no. 24, pp. 5570–5578, 2015.

[2] Z. Pan and J. Lu, "A Bayes-Based Region-Growing Algorithm for Medical Image Segmentation," in Computing in Science & Engineering, vol. 9, no. 4, pp. 32-38, July-Aug. 2007, doi: 10.1109/MCSE.2007.67.

[3] Luo-Wei Tsai, Jun-Wei Hsieh, Member, IEEE, and Kuo-Chin Fan, Member, IEEE, “Vehicle Detection Using Normalized Color and Edge Map” , 12 February 2007, p.850 - 864

[4] Husin, Z.B., Shakaff, A.Y.M., Aziz, A.H.A., Farook, R., 2013. Plant Chili disease detection using the RGB color model. Int. J. Digit. Content Technol. Appl. 7, 107–117. https://
doi.org/10.4156/jdcta.vol7.issue10.11.

[5] Huang, Q.Z., M., Huang, X., Li, P., Fu, H., Zhang, F., Tang, S., 2018. Segmentation of rice canopy image using the Otsu method based on visual spectral image color related indices. Guangdong Agric. Sci. 45, 120–125. https://doi.org/10.16768/j.issn.1004-874X.2018.01.020.

[6] Goswami, D., Kalkan, S., Krüger, N. (2009). Bayesian Classification of Image Structures. In: Salberg, AB., Hardeberg, J.Y., Jenssen, R. (eds) Image Analysis. SCIA 2009. Lecture Notes in Computer Science, vol 5575. Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-642-02230-2_69

[7] Joyce, James, "Bayes’ Theorem", The Stanford Encyclopedia of Philosophy (Fall 2021 Edition), Edward N. Zalta (ed.). https://plato.stanford.edu/archives/spr2019/entries/bayes-theorem/#2 (accessed Jul. 06, 2023).

[8] Chuong B. Do, “The Multivariate Gaussian Distribution,” 2008. Available: https://cs229.stanford.edu/section/gaussians.pdf

[9] Goswami, D., Kalkan, S., Krüger, N. (2009). Bayesian Classification of Image Structures. In: Salberg, AB., Hardeberg, J.Y., Jenssen, R. (eds) Image Analysis. SCIA 2009. Lecture Notes in Computer Science, vol 5575. Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-642-02230-2_69

[10] Y.-Y. Chuang, B. Curless, D. H. Salesin, and R. Szeliski, “A Bayesian approach to digital matting,” in Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001, 2005.

[11] Duchi, John (2014): "Derivations for Linear Algebra and Optimization" ; in: University of California, Berkeley ; URL: http://www.eecs.berkeley.edu/~jduchi/projects/general_notes.pdf .

[12] Kim T-H, White H (2003) On more robust estimation of skewness and kurtosis: Simulation and application to the S & P 500 index

[13] MacKay, David (2003). "Chapter 20. An Example Inference Task: Clustering" (PDF). Information Theory, Inference and Learning Algorithms. Cambridge University Press. pp. 284–292. ISBN 978-0-521-64298-9. MR 2012999.

[14] N. Otsu, "A Threshold Selection Method from Gray-Level Histograms," in IEEE Transactions on Systems, Man, and Cybernetics, vol. 9, no. 1, pp. 62-66, Jan. 1979, doi: 10.1109/TSMC.1979.4310076.

ภาคผนวก (Appendix)

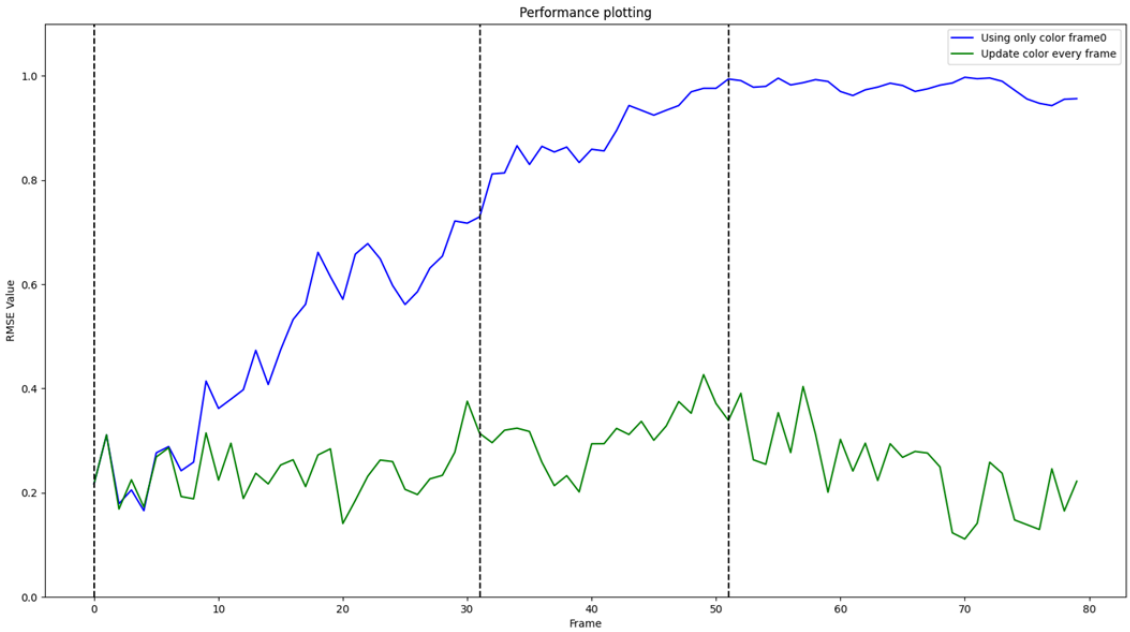

รูปที่ 57 Probability evaluation result with incremental learning

รูปที่ 57 แสดงผลลัพธ์ของการ evaluate probability image โดยเส้นสีฟ้าเป็นผลลัพธ์ของระบบติดตามที่เรียนรู้ด้วย frame แรกของการ tracking และเส้นสีเขียวคือผลลัพธ์ของระบบติดตามที่ประยุกต์ใช้เทคนิค incremental learning ซึ่งแสดงให้เห็นถึงแนวทางในการประยุกต์ใช้เทคนิคสำหรับการติดตามใน video ซึ่งจากในการทดสอบข้างต้นพบว่าในเฟรมที่ 51 ระบบไม่สามารถติดตามบริเวณที่สนใจได้แต่เมื่อประยุกต์ใช้เทคนิคนี้ทำให้ระบบสามารถติดตามบริเวณที่สนใจได้ตลอดทั้ง video sequence

Preliminary experiment 1: การทดลอง Color feature extraction กับรูปภาพห้องนอน

1.1 Proof of concept

ทางคณะผู้จัดทำต้องการทดลองหาความน่าจะเป็นที่มีความเหมือนกันในระบบ Color Bayesian Model ในรูปภาพห้องนอนเดียวกันโดยเลือกบริเวณที่สนใจสำหรับ training และเลือกบริเวณ testing อื่นๆภายในภาพห้องนอนที่กำหนดให้

1.2 Methodology

รูปที่ 58 Raw data สำหรับใช้งาน

1. ทางคณะผู้จัดทำเลือกรูปภาพสำหรับการทดสอบระบบเป็นรูปภาพห้องนอนโดยรูปภาพที่ใช้สำหรับการ training และ testing จะเป็นรูปเดียวกันและดังรูปภาพที่ 58

รูปที่ 59 รูปแสดงบริเวณสำหรับข้อมูล Training ของภาพ

2. ทางคณะผู้จัดใช้ภาพเดิมทำเลือกวงรี 1 วงสำหรับเป็นข้อมูลการ training ภายในระบบของเราโดยจะแสดงอยู่ในรูปลักษะวงกลมสีแดง ที่ปรากฏขึ้นบนรูปภาพที่ 59

รูปที่ 60 รูปแสดงบริเวณสำหรับข้อมูล Testing ของภาพ

3. ทางคณะผู้จัดทำใช้ภาพดั้งเดิมทำการเลือกวงรี 5 วงสำหรับทดสอบโดยเป็นข้อมูล testing ของระบบสำหรับหาหาความน่าจะเป็นที่บริเวณทั้ง 5 วงจากข้อมูล testing จะมีลักษณะเหมือนกันกับบริเวณ 1 วงจากข้อมูล training ที่ปรากฏขึ้นบนรูปภาพที่ 60

4. ทำการทดสอบระบบ Color Bayesian Model โดยหาความน่าจะเป็นที่บริเวณทั้งหมด 5 วงในข้อมูล testing ของรูปภาพจะมีลักษณะเหมือนกันกับบริเวณ 1 วงในข้อมูล training ของรูปภาพ และมีบริเวณที่มีลักษณะคล้ายกัน 1 วงซึ่งไม่ใช่พื้นที่ที่สนใจ

5. สังเกตและเก็บผลการทดลอง

1.3 Result

รูปที่ 61 รูปแสดงความน่าจะเป็นบริเวณ testing มีลักษณะเหมือนกันบริเวณ training เมื่อนำแต่ละ color channel ทดลองกับระบบ Color naive Bayes model (วงกลมสีฟ้าแค่แสดงบริเวณที่นำมา testing)

จากผลการทดลองรูปที่ 61 แสดงรูปภาพความน่าจะเป็นของบริเวณ testing นำไปทดสอบด้วยระบบ Color naive Bayes model การทดลองจะประยุกต์ใช้กับ color channel ประเภท RGB และรูปภาพความน่าจะเป็นจะแสดงด้วย color model แบบ grayscale โดยทางคณะผู้จัดทำจะพิจารณาหาความน่าจะเป็นทุกพิเซลภายในวงรีสีฟ้าเท่านั้นและนอกบริเวณวงรีกำหนดให้มีความน่าจะเป็นต่ำทั้งหมดโดยสีขาวคือบริ เวณ testing เมื่อนำไปทดสอบกับข้อมูล training ด้วยระบบ Color naive Bayes model มีความน่าจะเป็นที่จะมีลักษณะเหมือนกันและสีดำคือบริเวณ testing เมื่อนำไปทดสอบกับข้อมูล training ด้วยระบบ Color naive Bayes model มีความน่าจะเป็นที่จะมีลักษณะไม่เหมือนกัน

1.4 Conclusion

จากการทดลองทางคณะผู้จัดทำจะแสดงผลลัพธ์แค่บริเวณที่มีความน่าจะเป็นที่จะมีลักษณะเหมือนกันเมื่อนำบริเวณ testing ไปทดสอบกับข้อมูล training ด้วยระบบ Color naive Bayes model แต่ยังไม่ประยุกต์แสดงวงรีบนภาพจริงออกมา ผลที่ได้คือ Color naive Bayes model สามารถหาความน่าจะเป็นบริเวณ testing ที่มีลักษณะเหมือนกันบริเวณ training ได้แต่การประยุกต์ Color naive Bayes model จะเป็นการกำหนดให้ค่าสีที่นำมาทดสอบนั้นมีความเป็นอิสระต่อกันแต่ในความเป็นจริงสีใน RGB color model ที่นำมาทดลองนั้นมีความไม่เป็นอิสระต่อกัน ดั้งนั้นทางคณะผู้จัดทำประยุกต์การคำนวนทุก R-G-B color channel ด้วย multi gaussian variable และนำไปทดสอบกับสมการ Bayesian ในการทดลองต่อไป

Preliminary experiment 2: homogeneity area tracking

การทดลองนี้เป็นการ proof of concept สำหรับการใช้ส่วนเบี่ยงเบนมาตรฐานเป็นคุณลักษณะในการระบุลักษณะความเป็นเนื้อเดียวกันของพื้นที่ในภาพ โดยในการทดลองนี้ไม่รวมถึงการติดตามเป็นระบบในวิดิโอ และศึกษาความสามารถของการติดตามพื้นที่ที่มีเนื้อเดียวกันในระดับ resolution เดียวกับ source image นอกจากนี้ค่าทางสถิติที่ใช้ในการคำนวณความน่าจะเป็นของความเป็นเนื้อเดียวกันถูกเก็บจากข้อมูลคนละชุด

2.1 Hypothesis

ค่าทางสถิติของพื้นที่สามารถบ่งบอกความเป็นเนื้อเดียวกันของพื้นที่ในภาพได้แต่ด้วยระบบที่ติดตามด้วยความละเอียดเดียวสามารถติดตามพื้นที่ได้ในความลึกเดียวเท่านั้น

2.2 Methodology

1. ดึงคุณลักษณะจาก source image โดยการ sliding window ขนาด 3x3 เพื่อหาส่วนเบี่ยงเบนมาตรฐานในแต่ละ pixel ของภาพ
2. คำนวณความน่าจะเป็นที่จะเป็นเนื้อเดียวกันโดยใช้ข้อมูลทางสถิติที่ถูกเก็บจากข้อมูลคนละชุด
3. ประยุกต์หลักการ region-growing ในการแบ่งกลุ่มของพื้นที่ที่เป็นเนื้อเดียวกันซึ่งออกมาเป็น binary mask
4. นำ binary mask มาทำการคำนวณหา parameter ของวงรีโดยใช้หลักการทางสถิติ
5. สร้างวงรีเพื่อแสดงผลโดยทำการใช้ความมั่นใจของวงรีระดับ 0.900 และ 0.979

2.3 Result

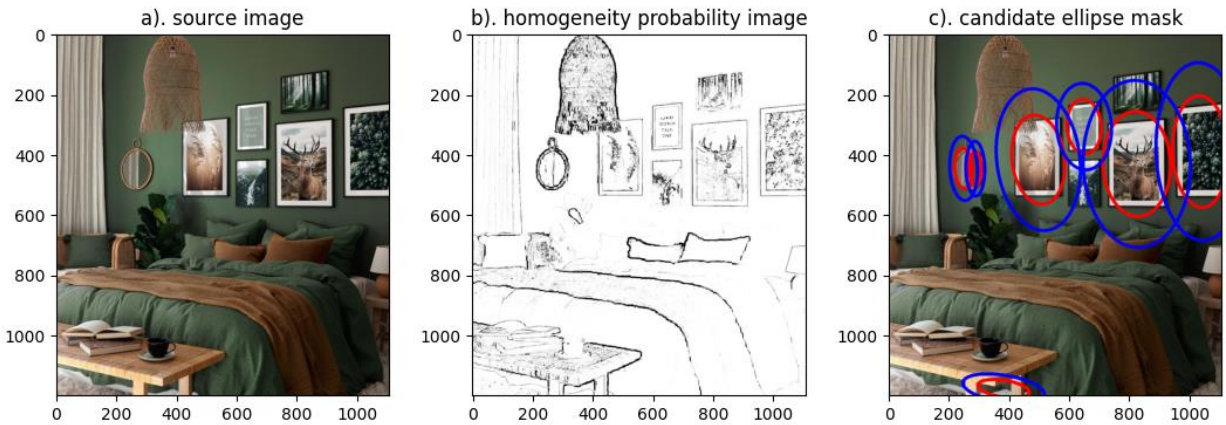

รูปที่ 62 แสดงผลลัพธ์ของ Preliminary experiment 2 โดยภาพ a) เป็นภาพที่ถูก input เข้าระบบ
b) แสดงค่าความน่าจะเป็นที่จะเป็นเนื้อเดียวกัน และ c) แสดงภาพผลลัพธ์ที่ได้จากการสร้างวงรีจากความน่าจะเป็นใน homogeneous region

จากรูปภาพที่ 62a. แสดงถึงภาพที่ใช้ในการติดตามพื้นที่ที่เป็นเนื้อเดียวกันโดยในภาพจะมีวัตถุที่มีความเป็นเนื้อเดียวกันหลากหลายความลึก นอกจากนี้ภาพบนผนังมีความหลากหลายใน texture เมื่อทำการคำนวณหาความน่าจะเป็นของความเป็นเนื้อเดียวกันดังภาพที่ 62b. โดย pixel ที่มีความขาวแสดงถึงความน่าจะเป็นที่เป็นเนื้อเดียวกันสูง เมื่อนำ probability image ไปทำการ segmentation โดยการใช้ region-growing และนำ binary mask ไปสร้างวงรีจะได้ผลลัพธ์ดังภาพ 62c.

จากผลลัพธ์ของ probability image ดังภาพที่ 62b. เมื่อทำการติดตามโดยใช้ส่วนเบี่ยงเบนมาตรฐานเป็นคุณลักษณะที่บ่งบอกถึงความเป็นเนื้อเดียวกัน และค่าทางสถิติถูกคำนวณจากข้อมูลคนละชุดกัน แสดงให้เห็นถึงความแปรปรวนของความน่าจะเป็นบนวัตถุที่มีความเป็นเนื้อเดียวกันแต่มี texture และไม่เป็นเนื้อเรียบซึ่งส่งผลให้ระบบไม่สามารถตรวจจับว่าเป็นพื้นที่ที่เป็นเนื้อเดียวกันได้ นอกจากนี้ลักษณะของการติดตามด้วยความละเอียดของภาพเดียวกับ source image สามารถตรวจจับพื้นที่เนื้อเดียวกันได้แต่ไม่ครอบคลุมในทุกความลึกของวัตถุซึ่งสามารถแก้ปัญหาได้ด้วยการตรวจจับโดยใช้หลักการ multi resolution image

2.4 Conclusion

ระบบตรวจจับพื้นที่ที่มีความเป็นเนื้อเดียวกันสามารถตรวจจับพื้นที่ที่มีความเรียบได้ด้วยส่วนเบี่ยงเบนมาตรฐานแต่เมื่อวัตถุมี texture มากทำให้การตรวจจับด้วยค่าทางสถิติที่ถูกเก็บในข้อมูลคนละชุดมีความแปรปรวนและไม่สามารถตรวจจับได้ นอกจากนี้เมื่อทำการติดตามด้วยภาพที่มีความละเอียดเดียวทำให้ระบบสามารถติดตามได้อย่างไม่ครอบคลุมทุกพื้นที่บนภาพ

Preliminary experiment 3: homogeneity area tracking

การทดลองนี้ทำการวิเคราะห์ลักษณะการกระจายตัวของข้อมูลที่ใช้ในการบ่งบอกถึงความเป็นเนื้อเดียวกันซึ่งในโครงงานนี้จะใช้เป็นค่าต่ำสุดและสูงสุดของค่าความแปรปรวน เพื่อทำ proof of concept ในการ represent ข้อมูลด้วยการกระจายตัวแบบปกติหรือ Gaussian distribution โดยข้อมูลที่นำมาใช้ทำการทดลองมาจาก CCEDD (cervical cell edge detection dataset) โดยทำการแบ่งข้อมูลเป็นสองชุดคือ homogeneous class และ non-homogeneous class โดยในการทดลองนี้จะทดลองบน grayscale image

3.1 Hypothesis

ลักษณะของข้อมูลที่บ่งบอกความเป็นเนื้อเดียวกันมีการกระจายตัวแบบปกติ หรือสามารถสร้างแบบจำลองข้อมูลได้ด้วยสมการการกระจายตัวแบบปกติ (Gaussian distribution)

3.2 Methodology

1. นำภาพ source image และ annotation จาก CCEDD มาแบ่งข้อมูลออกเป็นสองชุดคือ homogeneous class และ non-homogeneous class
2. ดึงคุณลักษณะจาก source image โดยการ sliding window ขนาด 3x3 เพื่อหาส่วนเบี่ยงเบนมาตรฐานในแต่ละ pixel ของภาพ
3. ประยุกต์ใช้ KDE เพื่อประมาณ distribution ของข้อมูลนำมาเปรียบเทียบกับการ model ข้อมูลด้วยการกระจายตัวแบบปกติ

3.3 Result

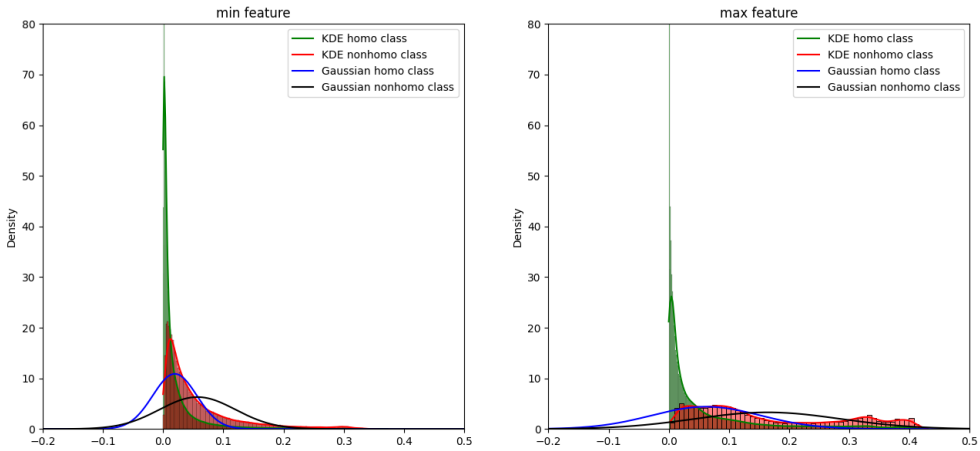

รูปที่ 63 histogram plot ของข้อมูล homogeneity

จากผลลัพธ์รูปที่ 63 แสดงให้เห็นว่าข้อมูล homogeneous class และ non-homogenous class มีลักษณะการกระจายตัวแบบเบ้ขวา โดยสีเขียวสำหรับ homogeneous class สีแดงสำหรับ non-homogeneous class เมื่อทำการสร้างแบบจำลองของข้อมูลด้วย Gaussian distribution แสดงให้เห็นดังภาพโดยกราฟสีฟ้าและสีดำแสดงถึง homogeneous class และ non-homogeneous class ตามลำดับจะพบว่าค่า mean ของ Gaussian distribution ที่ใช้ parameters จากข้อมูลของ homogeneous class ตรงกับ mode ของการทำ KDE กับข้อมูล non-homogeneous class ซึ่งหมายความว่าถ้า pixel นั้นมีค่าของ features อยู่ใน mode ของ non-homogeneous class หรือค่าที่มี population สูงที่สุดของ non-homogeneous class ค่า probability density function ของ homogeneous class จะสูงกว่า non-homogeneous class ซึ่งส่งผลให้การคำนวณค่าความน่าจะเป็นของ Bayes จะได้ผลลัพธ์ที่ความน่าจะเป็นของการเป็น homogeneous มากกว่า non-homogeneous ซึ่งทำให้การตรวจจับ homogeneous area เกิดข้อผิดพลาดได้

3.4 Conclusion

ลักษณะของข้อมูลที่บ่งบอกความเป็นเนื้อเดียวกันมีการกระจายตัวแบบเบ้ขวาซึ่งไม่สามารถสร้างแบบจำลองของข้อมูลด้วยการใช้สมการ Gaussian distribution การใช้การจำลองข้อมูลด้วย Gaussian distribution จะเกิดปัญหาเมื่อข้อมูล input เข้ามามีค่าอยู่ใน mode ของ non-homogeneous class ซึ่งจะทำให้การคำนวณความน่าจะเป็นที่จะเป็นเนื้อเดียวกันสูงส่งผลให้การตรวจจับ homogeneous area เกิดข้อผิดพลาด

Preliminary experiment 4: การทดลองเปรียบเทียบประสิทธิภาพทั้ง 3 models ประกอบไปด้วย normal distribution, multivariate gaussian distribution, และ multimodal distribution

4.1 Proof of concept

การทดลองนี้เป็นการทดลอง Proof of concept ว่า multimodal distribution จะมีประสิทธิภาพดีที่สุดที่จะนำมาประยุกต์ใช้กับระบบของ Region of interested tracking ในการหา probability image จากสมการของ Bayesian

4.2 Methodology

รูปที่ 64 รูปภาพ frame แรกสำหรับ training

1. ทางคณะผู้จัดทำเลือกรูปภาพสำหรับการทดสอบระบบทั้ง 3 models ประกอบไปด้วย Gaussian distribution, multivariate Gaussian distribution, และ multimodal distribution สำหรับเรียนรู้ด้วยรูปภาพเดียวกันดังรูปที่ 64 โดยรูปภาพที่เลือกมาจาก video frame แรก

รูปที่ 65 รูปภาพ frame สองสำหรับ testing

2. ทางคณะผู้จัดทำเลือกรูปภาพสำหรับการทดสอบระบบทั้ง 3 models normal distribution, multivariate gaussian distribution, และ multimodal distribution สำหรับทดสอบด้วยรูปภาพเดียวกันแสดงในรูปที่ 65 โดยรูปภาพที่เลือกมาจาก video frame สอง

รูปที่ 66 รูปแสดงบริเวณสำหรับ training ของภาพ

3. ทางคณะผู้จัดทำวงวงรี 1 วงสำหรับเป็นข้อมูลการ training ภายในภาพที่แสดงในรูปที่ 66 โดยรูปภาพที่เลือกมาจาก video frame แรกให้กับทั้ง 3 ระบบของโดยจะแสดงอยู่ในรูปลักษะวงกลมสีแดง ที่ปรากฏขึ้นบนรูปภาพที่ 10 และกำหนดให้ cluster ของกลุ่มสีเป็น 2 สำหรับนำไปประยุกต์ใช้กับ model multi-modal variate gaussian distribution
4. ทางคณะผู้จัดทำวงวงรี 1 วงสำหรับเป็นข้อมูลการ training ภายในภาพที่แสดงในรูปที่ 8 โดยรูปภาพที่เลือกมาจาก video frame แรกให้กับทั้ง 3 ระบบของโดยจะแสดงอยู่ในรูปลักษะวงกลมสีแดง ที่ปรากฏขึ้นบนรูปภาพที่ 66 และกำหนดให้ cluster ของกลุ่มสีเป็น 2 สำหรับนำไปประยุกต์ใช้กับ model multi-modal variate gaussian distribution

รูปที่ 67 รูปภาพ ground truth สำหรับเป็นตัวต้นแบบในการทดสอบ

5. ทางคณะผู้จัดทำสร้าง ground truth แสดงในรูปที่ 67 สำหรับเป็นตัวต้นแบบในการทดสอบความแตกต่างของภาพระหว่างภาพ ground truth กับภาพ probability image จากระบบทั้ง 3 models ประกอบไปด้วย normal distribution, multivariate gaussian distribution, และ multimodal distribution โดยหาความแตกต่างของภาพด้วย loss function ที่ประกอบไปด้วย MSE, RMSE, MAE
6. สังเกตและเก็บผลการทดลอง

4.3 Result

รูปภาพ probability image ของ model normal distribution, multivariate gaussian distribution, multimodal distribution ดังรูป

รูปที่ 68 รูปภาพ probability image ของ model normal distribution, multivariate gaussian distribution และ multimodal distribution ตามลำดับ

ตารางที่ 1 ตารางเปรียบเทียบความแตกต่างของภาพ

Model	Score		
	MAE	MSE	RMSE
Normal distribution	0.26087	0.13672	0.36975
Multivariate gaussian distribution	0.21721	0.11561	0.34002
Multi-modal gaussian distribution	0.21239	0.10525	0.32442

จากผลการทดลองจะได้ probability image ที่จะแสดงด้วย color model แบบ grayscale ของทั้ง 3 models ซึ่งจะแสดงในรูปภาพที่ 17 โดยทางคณะผู้จัดทำได้ทดสอบหาความน่าจะเป็นทุกพิเซลในรูปภาพ testing กับข้อมูลการเรียนรู้ก่อนหน้าในรูปภาพ training ซึ่งความหมายของสีขาวคือบริเวณที่มีความน่าจะเป็นที่จะมีลักษณะเหมือนกันแต่สีดำคือบริเวณที่มีความน่าจะเป็นที่จะมีลักษณะไม่เหมือนกัน และสุดท้ายนำรูปภาพ probability image เปรียบเทียบกับ ground truth ด้วย loss function MSE, RMSE, MAE โดย concept ของการเปรียบเทียบจะเป็นการนำภาพจริงลบกับภาพที่เกิดขึ้นจากความน่าจะเป็นและนำมาคำนวนความต่าง ยิ่งค่าเข้าใกล้ 0 แสดงว่าทั้ง 2 ภาพมีลักษณะที่เหมือนกันมากซึ่งผลลัพธ์ที่มีค่าน้อยที่สุดและมีความใกล้เคียงกับภาพ ground truth มากที่สุดคือ model multi-modal Gaussian distribution

4.4 Conclusion

Models ของตัว multimodal distribution ได้ผลลัพธ์ที่วัดจาก loss function MAE, MSE, RMSE ที่มีความแตกต่างน้อยที่สุดเมื่อเปรียบเทียบค่า probability image ที่ได้จากประยุกต์ใช้สมการ Bayesian ของตัว model multimodal distribution กับภาพ ground truth ทำให้ทางคณะผู้จัดทำได้เลือกนำตัว models ของตัว multimodal distribution ไปประยุกต์ใช้ใน system หลักของ Region of interested tracking